Bài toán và đầu ra của dự án

Sales & Customer Analytics Warehouse | Portfolio Data Engineer | Olist thật, demo trên một máy.

INPUT

7 feed Olist v2

451.535 dòng nguồn; 99.441 orders

Customer, product, seller, orders, items, payments, category translation

ZIP bất biến + checksum + provenance

Snapshot lịch sử; không phải CDC / OLTP

NỀN TẢNG

Dữ liệu đúng và truy vết được

Python + MinIO + PostgreSQL

dbt → Kimball: 7 dims, 3 facts

MetricFlow + governed SQL analysis

Airflow: lịch, retry, logs và publication

OUTPUT ĐÃ CÓ

Dữ liệu phục vụ quyết định

8 KPI lõi; 5 metric exports

6 dashboard Superset; 60 đối tượng

8 SQL analyses + notebook + CSV

Lineage, DQ, replay và recovery evidence

NGƯỜI DÙNG

Business/BA: hiểu biến động, cơ cấu, khách hàng và giao hàng. DE: đối soát, truy nguồn, xem lỗi và khôi phục.

TIÊU CHÍ THÀNH CÔNG

KPI khớp SQL; không nhân đôi khi replay; lỗi không công bố dữ liệu dở; mọi chart cùng release đã kiểm chứng.

PHẠM VI CÓ CHỦ ĐÍCH

Không telesales / dữ liệu bệnh nhân / streaming / MPP / HA. Không có cost, target hay lợi nhuận; không giả dữ liệu Olist thành dữ liệu dược phẩm.

Kiến trúc hệ thống đang chạy

Docker Compose project salesdw | PostgreSQL là analytical Warehouse; không có OLTP riêng trong v1.

APACHE AIRFLOW 02:00 Asia/Ho_Chi_Minh • 9 tasks • retries • logs • trạng thái thực

01 SOURCE
Olist snapshot
- 7 CSV trong ZIP v2
- SHA-256 cố định
- Không có source CDC

→

02 RAW / AUDIT
Python + MinIO
- Giữ nguyên raw archive
- Receipt / artifact metadata
- S3-compatible object storage

→

03 POSTGRESQL
Validate + landing
- Schema / ID / conflict checks
- Accepted source versions
- Chốt source_cut

→

04 WORKING MODELS
dbt Core
- 7 staging + 1 intermediate
- 7 dims + 3 facts
- Tests / incremental / keys

↓

05 FREEZE / VALIDATE
Kimball snapshot
- warehouse_store schema
- 7 dimensions + 3 facts
- Immutable, release-scoped

←

06 SEMANTICS
Local MetricFlow
- 8 KPI khai báo trong dbt
- Bind candidate release
- CLI + SQL oracle parity

←

07 SERVING
Published reporting
- 5 MetricFlow exports
- Analytical SQL views
- Atomic publication gate

←

08 CONSUMER
Apache Superset
- 6 dashboard + SQL Lab
- Read-only reporting views
- Cùng published release

POSTGRESQL sales_dw: landing / work / warehouse_store / semantic_input / reporting / ops

Mỗi lớp dữ liệu có một trách nhiệm

Raw → accepted versions → working models → immutable DWH → governed serving. Không phải Delta Lake.

RAW	**MinIO + original ZIP** Byte gốc + SHA-256	Audit, replay; không sửa bản gốc
LANDING	**landing.source_versions** Source cut + accepted payload	Row lineage → file / dòng / hash
TRANSFORM	**work.stg_* / int_* / dim_* / fct_*** dbt models có thể build lại	Tests; checkpoint; key registry
WAREHOUSE	**warehouse_store.dim_* / fct_*** Typed Kimball snapshot theo release	PK / FK / grain / reconciliation
SEMANTIC	**semantic_input + MetricFlow** Release-bound query definitions	8 KPI; 5 exports; SQL parity
SERVING	**reporting.* → Superset / SQL** Metric tables + analytical views	Chỉ published; role BI read-only

TRUY VẾT Chart → query / release → fact / dimension → source version → file / row / checksum

Kimball bus matrix và grain

Ba business process chia sẻ conformed dimensions; mỗi process có star schema theo đúng grain.

PROCESS → GRAIN → DIMENSIONS → MEASURES

PROCESS / FACT	Purchase date	Milestone dates	Customer	Product	Seller	Buyer geography	Order status	Payment method
Sales lines fct_order_items	X	-	X	X	X	X	X	-
Payment records fct_payments	X	-	X	-	-	X	X	X
Order fulfillment fct_orders	X	X	X	-	-	X	X	-

Một dòng hàng

source + order_id + order_item_id

Transaction fact; item_id là ordinal

Một payment record

source + order_id + payment_sequential

Transaction fact; installments không cộng

Một đơn hàng

source + order_id

Accumulating snapshot; 5 date roles

QUY TẮC BẤT BIẾN

Integer dimension SKs ổn định • order_id là degenerate dimension • aggregate từng fact rồi drill-across • không join atomic facts để SUM.

Ba star dùng chung bảy dimensions

Sơ đồ logic để trình bày. Dimension chung được lặp trên hình, không phải nhân bản bảng vật lý.



KHÓA DIMENSION

Registry cấp bigint SK; date key YYYYMMDD; Unknown = 0, N/A = -1. Inferred member được bổ sung mà giữ key.

LỊCH SỬ NGUỒN

Olist thật chỉ có snapshot Type 0/1. Type 2 có explicit effectivity được kiểm bằng fixture cô lập, không phải lịch sử Olist.

Workflow thực tế của Airflow

DAG sales_warehouse_pipeline | 9 tasks | 02:00 mỗi ngày | tối đa 2 retries, cách nhau 30 giây.



FAILURE ĐƯỢC GHI ĐÚNG

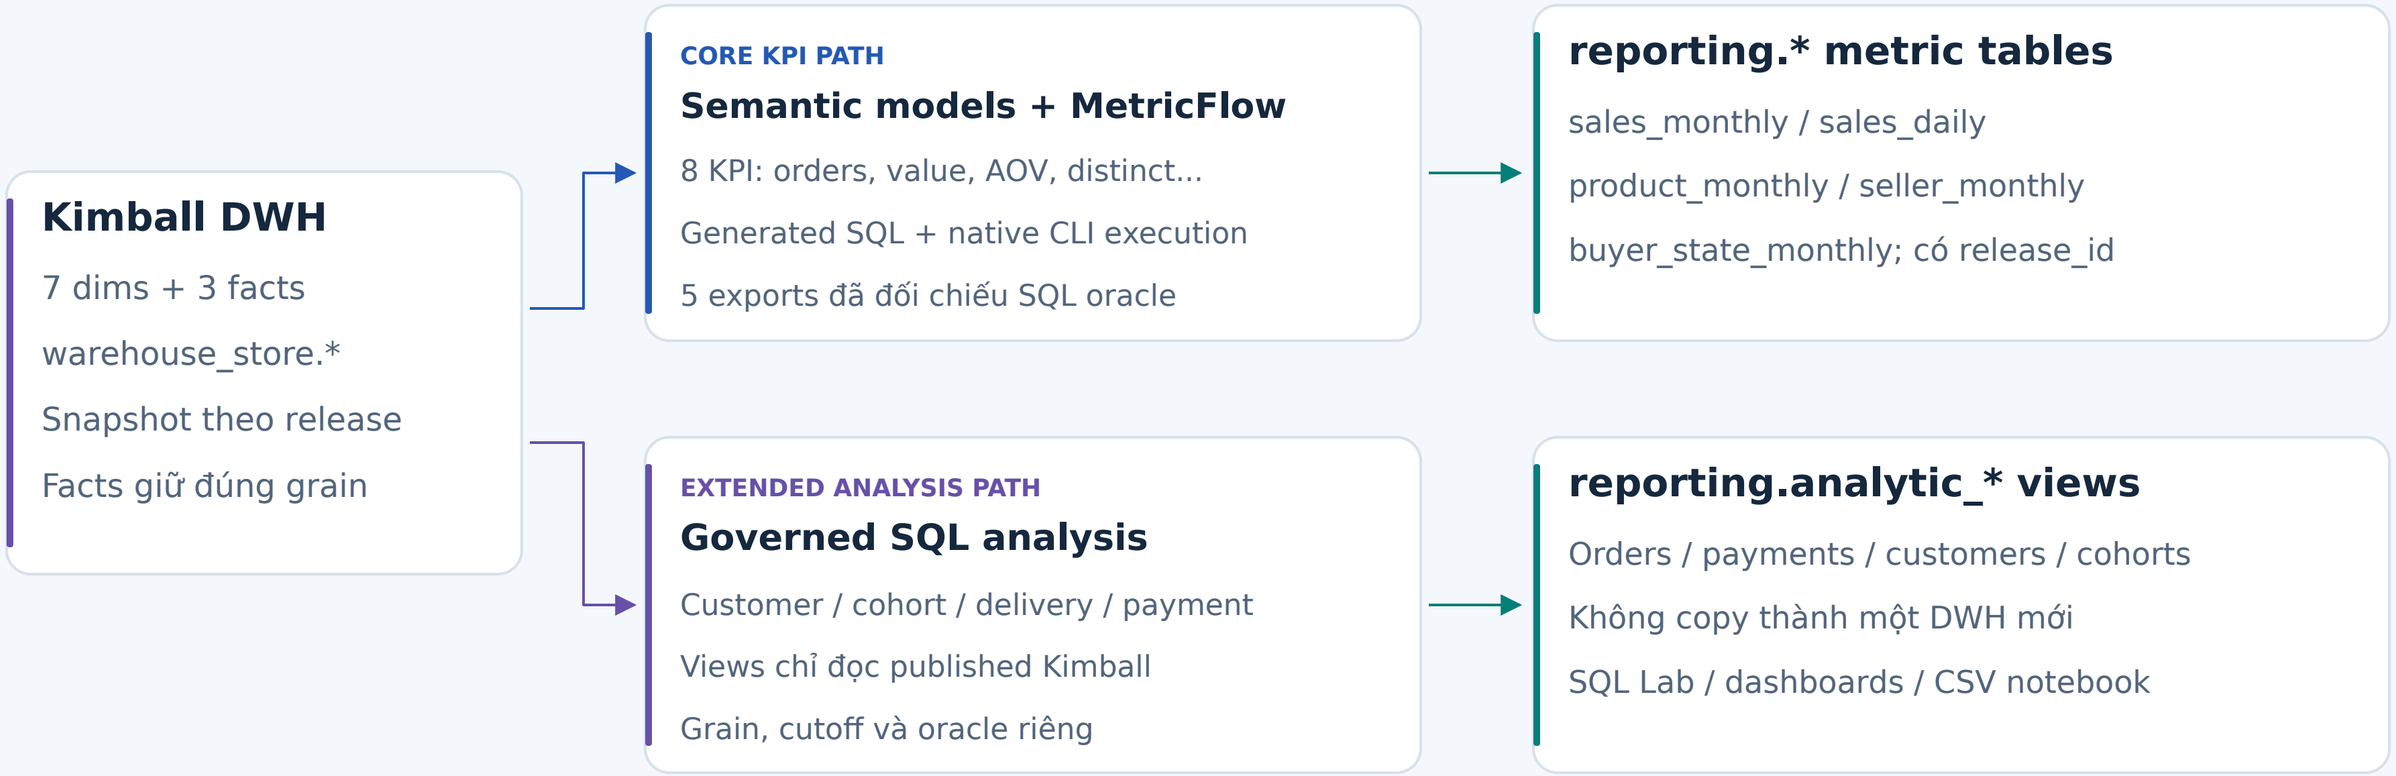
Task terminal fail → ledger failed; downstream upstream_failed; không đổi published release. Không có task thông báo che lỗi.

ĐÃ TÁI HIỆN TRÊN RUNTIME

Load thử 1 lỗi, thử 2 thành công. Raw lỗi cả 3 lần → DAG failed. Replay và late-arrival kiểm riêng trong database cô lập.

Semantic Layer nằm ở đâu?

Một DWH, hai đường serving được quản trị; không dựng Warehouse thứ hai và không dùng API semantic trả phí.



SUPERSET READ-ONLY • PUBLISHED RELEASE ONLY

AOV = tổng giá trị / tổng đơn delivered; mẫu số 0 → NULL. Distinct tính tại đúng kỳ, không SUM theo ngày. Không join atomic item × payment để tính tiền.

Không công bố dữ liệu đang xử lý dở

R0 / R1 là nhãn minh họa release. Publication là giao dịch trong PostgreSQL, không phải distributed transaction.

1 Build candidate R1

Fixed source_cut

dbt tests + DQ gates

2 Snapshot R1

7 dims + 3 facts

Same-release FK / hashes

3 Semantic R1

5 exports đầy đủ

Binding + SQL parity

4 Publish R1

Owner + fence hợp lệ

Atomic pointer + event

CONSUMER ĐỘC LẬP VỚI WORKING STATE

Superset đang pin R0 → mọi chart tiếp tục đọc cùng R0

Sau publish: bàn giao URL pin R1 là bước riêng; pipeline không tự sửa dashboard đang mở.

CHECK FAIL / EXPORT THIẾU

R1 không được publish; giữ R0. Source warning được giải thích; schema, grain, FK, parity errors phải chặn.

RETRY / ACK MẤT

Replay không nhân đôi source versions. Sau commit bị mất ACK: xác minh output đã lưu; không tự ghi lại hoặc reset.

RESTORE ĐÃ KIỂM RIÊNG

DWH vào target mới: 102,056 giây; live không bị ghi đè. App restore / host-loss recovery chưa nghiệm thu.

Kết quả để trình bày trong buổi demo

Tháng kinh doanh 07/2018 | Cutoff khách hàng 31/08/2018 | Release handoff 87f01740.

Giá trị hàng delivered

867.953,46

BRL; chưa gồm freight

Đơn delivered

6.159

6.100 khách phân biệt

AOV delivered

140,92

BRL / delivered order

Giao đúng hẹn

96,62%

5.948 / 6.156 eligible

Tổng quan kinh doanh

Quy mô, biến động và nên xem sâu ở đâu?

Hiệu quả bán hàng

Đơn / khách / AOV / MoM / YoY / hủy

Sản phẩm & nhà bán hàng

Category, seller và khu vực đóng góp

Khách hàng & mua lại

Repeat, recency, cohort; cutoff cố định

Giao hàng & thanh toán

Đúng hẹn, thời gian giao, phương thức

Chất lượng dữ liệu & vận hành

Published release, DQ và audit runs

KIỂM CHỨNG HIỆN TẠI

60 chart queries + 8 SQL Lab queries; 6 browser pages; nhận xét đổi theo tháng ở 4 trang; 14 actual navigation clicks.

GIỚI HẠN CỦA KẾT QUẢ

Dữ liệu lịch sử Olist, không phải Abbott. Không target / cost / profit / lý do hủy. Single-host local; không tuyên bố production-ready.

Thiết kế bảng và quan hệ Kimball

Cột rút gọn từ migration 001. Khóa đầy đủ luôn có release_id; nét nối biểu diễn FK dimension → fact.

dim_date

date_key int YYYYMMDD
full_date, month_start
day, month, quarter, year

dim_customer

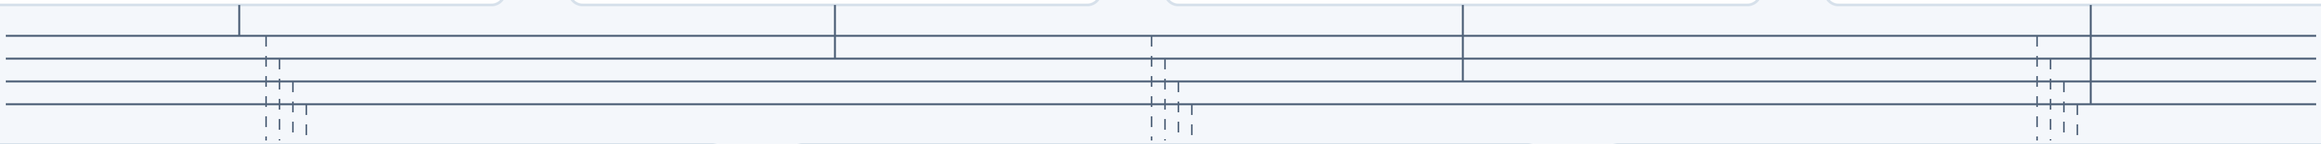
customer_key bigint SK
customer_unique_id
source_system, is_inferred

dim_buyer_geography

buyer_geography_key bigint SK
postal_prefix, city, state
Order-time address tuple

dim_order_status

order_status_key bigint SK
status_code
is_delivered, is_canceled



fct_order_items

PK release_id + order_item_key
UK source + order_id + item ordinal
FK customer / geography / status / date
FK product_key, seller_key
merchandise_value, freight_value
item_row_count = 1

fct_orders

PK release_id + order_key
UK source + order_id
FK customer / geography / status
FK 5 role-playing date keys
order / delivered / canceled counts
child totals, milestone timestamps

fct_payments

PK release_id + payment_key
UK source + order_id + pay sequence
FK customer / geography / status / date
FK payment_method_key
recorded_payment_value, record_count
payment_installments (non-additive)

dim_product

product_key bigint SK
product_id, category
valid_from / valid_to

dim_seller

seller_key bigint SK
seller_id
city, state, postal

PK/UK/FK: cùng release_id.
Mọi bảng có lineage / source_cut / run IDs.
Không nối facts để cộng số tiền.

dim_payment_method

payment_method_key bigint SK
payment_type