Từ dữ liệu rời rạc đến số liệu đáng tin cậy

Mục tiêu: cùng một định nghĩa, cùng một phiên bản dữ liệu, có thể đối soát và khôi phục.

01 INPUT

Dữ liệu kinh doanh thật

Olist v2 • 7 feed • 451.535 dòng

Customer, product, seller, order, item, payment, category translation

Snapshot + checksum + provenance

Fixture lỗi/cập nhật tách riêng dữ liệu thật

02 HỆ THỐNG

Một nguồn phân tích nhất quán

Ingest → kiểm tra → hợp nhất

Kimball Warehouse + dbt

Semantic Layer + metric exports

Airflow + kiểm thử + audit + recovery

03 OUTPUT MỤC TIÊU

Dữ liệu và kết quả có thể dùng

7 dimensions + 3 facts

8 KPI dùng chung, 5 metric exports

3 dashboard: sales, commercial, health

SQL phân tích + lineage + evidence

AI DÙNG VÀ ĐỂ LÀM GÌ?

Business/Analyst: xem bán hàng, khách hàng, danh mục.
DE/Operator: truy vết, xử lý lỗi, chạy lại và khôi phục.

THÀNH CÔNG ĐƯỢC ĐO BẰNG GÌ?

Số liệu đối soát đúng; replay không nhân đôi; lỗi không được publish; SQL, semantic và BI cùng định nghĩa.

NGOÀI PHẠM VI

Telesales • dữ liệu bệnh nhân • MPP • streaming • HA đa máy. Không gán ngành dược cho dữ liệu thương mại Olist.

Dữ liệu thật đủ để làm và đối soát

Một nhà công bố, bảy domain feeds; không gọi bảy file là bảy hệ thống độc lập.

FEED NGUỒN	SỐ DÒNG	VAI TRÒ
customers	99.441	Tham chiếu khách/địa chỉ
orders	99.441	Đơn và milestone
order_items	112.650	Dòng hàng, giá, freight
payments	103.886	Bản ghi thanh toán
products	32.951	Danh mục sản phẩm
sellers	3.095	Người bán
category_translation	71	Dịch tên category
TỔNG TRONG PHẠM VI	**451.535**	

BASELINE TÍNH TRỰC TIẾP TỪ NGUỒN

96.478 đơn delivered
93.358 khách có đơn delivered
13.221.498,11 giá trị hàng, chưa gồm freight

CẢNH BÁO THỰC TẾ ĐÃ PHÁT HIỆN

775 đơn không có items; 1 đơn không có payment
610 sản phẩm thiếu category
8 đơn delivered thiếu ngày nhận
303 matched orders lệch tiền trên 0,01

IDENTITY KHÔNG ĐƯỢC NHẦM

99.441 customer references → 96.096 khách phân biệt

GIỮ NGUYÊN BẢN GỐC

ZIP 44.717.580 bytes + SHA-256 + manifest. Geolocation/reviews ngoài phạm vi; không lấy số dòng đó để phóng đại số giao dịch.

GIỚI HẠN VÀ QUYỀN SỬ DỤNG

Không có currency/timezone/CDC; BRL là quy ước demo. Olist: CC BY-NC-SA 4.0, giữ attribution.

Kiến trúc tổng thể: nguồn → Warehouse → BI

Airflow điều phối; dbt quản lý transformation; MetricFlow sở hữu logic KPI dùng chung.

APACHE AIRFLOW Schedule • dependencies • retries • logs • trạng thái đúng • failure handling

01 SOURCE
Nguồn Olist
- 7 CSV nghiệp vụ
- Manifest + SHA-256
- Fixture tổng hợp tách riêng

→

02 INGEST
Python ingestion
- Schema / row validation
- Batch, receipt, record hash
- Reject → quarantine

→

03 PRESERVE
MinIO raw
- Source-native bất biến
- Audit, replay từ bản gốc
- Artifact identity

→

04 ADMIT
PostgreSQL landing
- Accepted source versions
- Load transaction + ledger
- Chốt source_cut

↓

05 TRANSFORM
dbt working models
- Staging → intermediate
- Kimball dims / facts
- Tests + checkpoints

←

06 FREEZE
Warehouse snapshot
- 7 dimensions + 3 facts
- Typed, immutable release
- FK trong cùng release

←

07 SEMANTICS / PUBLISH
MetricFlow + exports
- Bind một release
- 5 exports + SQL parity
- Publish sau mọi gate

←

08 CONSUME
Metabase / SQL
- Published releases only
- Mọi card pin release_id
- Analyst read-only views

XUYÊN SUỐT Contracts • DQ • lineage • least privilege • lease fencing • backup / restore • retention

Kimball: thiết kế theo business process và grain

Bus matrix tích hợp ba process bằng conformed dimensions; không phải ba star schema rời rạc.

BUSINESS PROCESS → GRAIN → DIMENSIONS → FACTS

BUSINESS PROCESS / FACT	Purchase date	Other dates	Customer	Product	Seller	Buyer geography	Order status	Payment method
Sales lines fct_order_items	X	-	X	X	X	X	X	-
Payment records fct_payments	X	-	X	-	-	X	X	X
Order fulfillment fct_orders	X	X	X	-	-	X	X	-

Một dòng hàng

source + order_id + order_item_id

Transaction fact

Một payment record

source + order_id + payment_sequential

Transaction fact; không phân bổ về item

Một đơn hàng

source + order_id

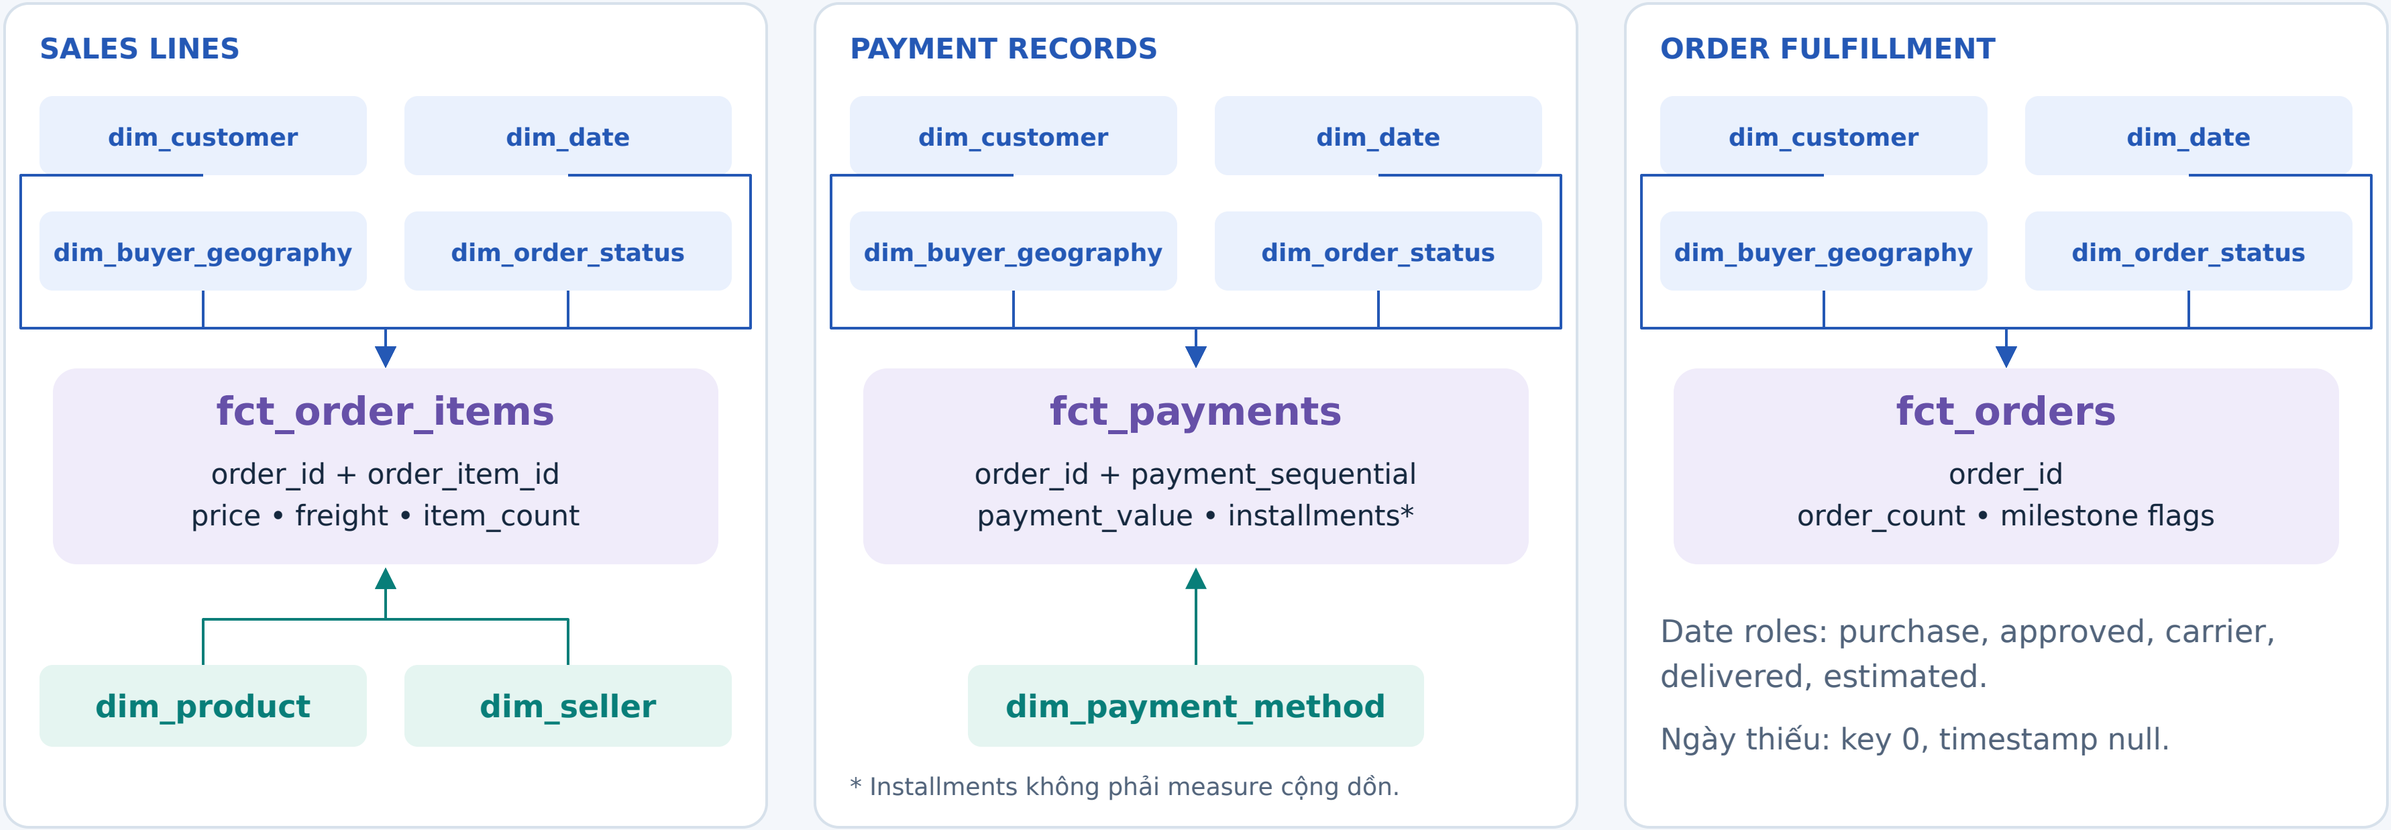
Accumulating snapshot; 5 date roles

NGUYÊN TẮC TÍCH HỢP

Integer surrogate keys ổn định • date key YYYYMMDD • order_id là degenerate dimension • aggregate riêng từng fact rồi drill-across.

Warehouse constellation: ba fact, bảy dimension

Dimension lặp lại trên hình để dễ đọc; trong Warehouse chúng là cùng một định nghĩa và key registry.



KHÓA VÀ LỊCH SỬ

Registry cấp integer SK; Unknown = 0; N/A = -1; inferred giữ nguyên key khi bổ sung thuộc tính.

RANH GIỚI CHÍNH XÁC

FK cùng release_id; không fact-to-fact join. Olist Type 0/1; Type 2 kiểm tra bằng fixture có effectivity.

Pipeline: mỗi bước có trách nhiệm và điểm kiểm soát

Luồng logic dự kiến do Airflow điều phối; không phải ảnh chụp DAG đã triển khai.



KHI LỖI Ở BẤT KỲ BƯỚC NÀO

Giữ bản published trước; log + failed state; không promote candidate lỗi. Chẩn đoán rồi retry/resume đúng batch/cut.

CHẠY LẠI AN TOÀN

Same revision + hash → no-op nghiệp vụ. Receipt vẫn được audit. Source conflict → quarantine; stale fence → từ chối publish.

Semantic Layer: định nghĩa một lần, tính đúng grain

Ví dụ AOV: tổng giá trị hàng delivered / số đơn delivered, không lấy trung bình các AOV con.

fct_order_items

SUM(price), status = delivered

Aggregate tại grain chung

purchase month + buyer state

fct_orders

SUM(delivered_order_count)

Aggregate tại grain chung

purchase month + buyer state

METRICFLOW

Drill-across → metric

Join kết quả đã aggregate, không join fact rows

AOV = tổng tử số / tổng mẫu số

Mẫu số 0 → null; làm tròn khi hiển thị

5 VERSIONED EXPORTS → METABASE

KPI chung; không viết lại công thức từng chart

VÍ DỤ TỔNG HỢP: JOIN NHÂN SỐ LIỆU

1 đơn × 2 item × 2 payment: tổng item đúng = 150; join chéo ra 300. Giữ nguyên grain và aggregate riêng để loại fanout.

DIMENSION PHẢI PHÙ HỢP METRIC

Item metrics dùng category/seller. AOV và tổng đơn chỉ dùng dimension chung theo hợp đồng; không tự phân bổ xuống item.

DISTINCT KHÔNG CỘNG DỒN

Khách xuất hiện nhiều ngày/bang vẫn là một khách ở tổng kỳ. Query trực tiếp tại đúng period/group; không SUM các distinct con.

Không để pipeline chạy dở làm sai báo cáo

Một release gắn cả dimensions, facts và metric exports; dữ liệu candidate chưa được BI nhìn thấy.

CANDIDATE PATH / R1 LÀ VÍ DỤ

Chốt source_cut

Nguồn và version cố định

Working build + DQ gates

→

Freeze snapshot R1

7 dims + 3 facts bất biến

PK / grain / same-release FK

→

MetricFlow bind R1

5 exports cùng release

SQL / semantic parity đạt

→

Fenced publication

Kiểm tra owner + fence

DB transaction: publish + pointer

↓

CONSUMER PATH

R0 vẫn phục vụ trong khi R1 được kiểm tra

→

Sau publish: link mới pin R1

Mọi card cùng release_id; link R0 còn hợp lệ khi được giữ lại

R1 LỖI / EXPORT THIẾU

Không đổi pointer. Giữ R0. Candidate + logs còn để chẩn đoán và chạy lại có kiểm soát.

STALE OWNER / ACK BỊ MẤT

Fence hết hạn không được publish. Mất ACK sau commit: tra release đã publish, không giả định rollback.

RANH GIỚI GIAO DỊCH

Atomic trong PostgreSQL. Metabase link/API là bước bàn giao riêng; lỗi bàn giao ghi nhận delivery lag.

Đầu ra phải có bằng chứng, không chỉ có sơ đồ

Tách ba lớp: đã kiểm chứng offline • gate runtime phải chạy sau • mục tiêu vận hành phải đo.

CURRENT / OFFLINE

Đã có bằng chứng thật

Nguồn đã tải + checksum + profile

451.535 dòng đã kiểm tra source contracts

137 kiểm tra thiết kế / fixture / DDL tĩnh

5 semantic checks offline, không kết nối DB

20 requirements + 20 work items có traceability

PLANNED / RUNTIME GATES

Phải chứng minh khi triển khai

Docker boot + controlled migration + dữ liệu vào DB

MetricFlow thực thi thật, source / SQL / KPI parity

Replay, failure recovery, concurrent publication

3 dashboard pin release + quyền truy cập đúng

22 scenario đã đặc tả; restore drill có đo thời gian

MỤC TIÊU THIẾT KẾ - CHƯA PHẢI KẾT QUẢ ĐÃ ĐO

≤ 10 phút
Batch accepted → published

p95 ≤ 5 giây
Query dashboard • 1-2 người xem

RPO ≤ 24 giờ
Logical failure; backup + raw

RTO ≤ 30 phút
Restore trên host khỏe

GIỚI HẠN VẬN HÀNH

<70 GB toàn bộ footprint • Một máy, không HA • Backup cùng host không bảo vệ mất host